




Neuralink: Fast LLM Inference on Smartphones with Neuron Co-Activation Linking

Tuowei Wang*, Ruwen Fan*, Minxing Huang, Zixu Hao, Kun Li, Ting Cao, Youyou Lu, Ju Ren⁺
Tsinghua University, Microsoft Research

关键词: Mobile Computing, Large Language Model, Model Sparsity, Parameter Storage

※ 研究背景

端侧大模型因其实时性、经济性、和安全性等方面的优势，正受到越来越多的关注。由于端侧设备（如：手机）的 DRAM 内存空间通常相对受限，端侧大模型部署通常采用“激活稀疏+异构存储”的方式，即将模型参数存放在 Flash 存储上，推理时动态加载部分参数到 DRAM 内存，利用模型稀疏性完成相应计算。这一方法缓解了内存压力，但是 **I/O 通信成为了新的瓶颈**。




Model	Compute	I/O	Total	I/O Ratio
OPT-350M	82 ms	776 ms	858 ms	90.4%
OPT-1.3B	202 ms	988 ms	1,190 ms	83.0%
OPT-6.7B	804 ms	2,224 ms	3,028 ms	73.4%
Llama-2-7B	609 ms	10,388 ms	10,997 ms	94.5%
Mistral-7B	540 ms	12,220 ms	12,760 ms	95.8%
MobiLlama-1B	230 ms	1,909 ms	2,139 ms	89.2%
Phi-2-2.7B	461 ms	1,976 ms	2,437 ms	81.1%

※ 核心观察

观察 1: 端侧设备通常使用 UFS 作为存储介质，其 I/O 瓶颈主要来源于 **I/O Operations Per Second (IOPS) 受限**而非带宽受限。

观察 2: 激活稀疏天然会引入大量**不连续的访存模式**，这使得 IOPS 受限的问题在端侧场景下尤为突出。


观察 3: 激活稀疏下的模型神经元呈现出显著的**共同激活现象**，即某些神经元往往与一组相对固定的其他神经元同时被激活。



不同读取长度下的 UFS 有效带宽

Ratio	dense	10%	20%	30%	40%
Bandwidth	1637.61	1355.35	1089.24	904.69	746.03
Latency	234.49	254.96	281.96	297.10	308.76
Speedup	-	0.92	0.83	0.79	0.76
Ratio	50%	60%	70%	80%	90%
Bandwidth	598.82	524.50	441.33	396.43	368.05
Latency	320.63	292.78	260.86	193.68	104.18
Speedup	0.73	0.80	0.90	1.21	2.25

不同稀疏比下模型推理的时延和带宽，受有效带宽下降影响，稀疏比需要达到 80% 才有加速比




模型神经元共同激活矩阵

※ 关键方法

核心思想: 修改存储上参数排布，将频繁被共同激活的参数排布在一起，从而提升访存连续性，减少 I/O 时延。




方法 - 离线阶段: 将神经元抽象为图节点，统计神经元共同激活频率作为节点间距离，利用最短哈密顿路径算法寻找最优排布。

方法 - 在线阶段: 灵活合并相近神经元链，进一步增加访存连续性；针对性设计缓存管理策略，优先缓存非连续神经元。



离线: 神经元存储排布算法，将共同激活频次视为距离，启发式地寻找最短哈密顿路径。 在线: 选择性连续读取相近神经元链。

※ 实验结果



实验结果:

- 3 个硬件设备，7 个大模型，8 个数据集
- 端到端延迟: 较 llama.cpp 2.37× 提升
- 带宽利用率: 较 llama.cpp 3.28× 提升

核心贡献: 缓解端侧 IOPS 受限，逼近带宽上限。

